

Trabalho 3 - Avaliação de PNL

Otimização 2025.1

Pedro Saito
122149392

Marcos Silva
122133854

Milton Salgado
122169279

1. Questão 1

Enunciado: Para os seguintes problemas de otimização não linear irrestrita, estude de forma detalhada e conceitual, as condições de otimalidade de primeira e segunda ordem, apresentando todos os cálculos. Ache os pontos críticos, extremo local e global se existirem.

1.1) Minimize $x_1 x_2$, $(x_1, x_2 \in \mathbb{R})$.

As condições de otimalidade de primeira ordem garantem que, para que um ponto x^* seja um mínimo ou máximo local de f , é necessário que o gradiente em x^* seja nulo, isto é,

$$\nabla f(x^*) = 0.$$

Desse modo, como o gradiente da função f é dado por (x_2, x_1) , seu único ponto crítico é $(0, 0)$. Com isso, vamos analisar as condições de otimalidade de segunda ordem para a matriz Hessiana de f .

Dada uma função de duas variáveis $f(x) = f(x_1, x_2)$ com os pontos críticos $(0, 0)$, calcularemos as derivadas de segunda ordem para cada componente. Assim, teremos:

$$H_1 = \left[\frac{\partial^2 f}{\partial x_1^2}(x^*) \right] = [0] \quad \text{e} \quad H_2 = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}(x) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(x) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(x) & \frac{\partial^2 f}{\partial x_2^2}(x) \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

Pelo critério de menores principais em \mathbb{R}^2 , vamos analisar os determinantes:

$$\det(H_1) = 0 \quad \text{e} \quad \det(H_2) = -1$$

Como podemos observar, o primeiro determinante $\det(H_1)$ é zero e, portanto, o teste é *inconclusivo*. Realizando uma análise da função nos quadrantes de f temos:

- Para $x_1 > 0$ e $x_2 > 0$: $f > 0$.
- Para $x_1 < 0$ e $x_2 < 0$: $f > 0$.
- Para $x_1 > 0$ e $x_2 < 0$: $f < 0$.
- Para $x_1 < 0$ e $x_2 > 0$: $f < 0$.

Com efeito, a origem $(0, 0)$ é um **ponto de sela**, pois a função assume apenas valores positivos em alguns quadrantes e negativos em outros, indicando a presença de direções de crescimento e decréscimo próximas ao ponto crítico. Assim, como não tem pontos de mínimo, a função f é **ilimitada**. ■

1.2) Minimize $(x_1 - 1)^2 - x_1 x_2 + (x_2 - 1)^2, (x_1, x_2 \in \mathbb{R}^2)$.

Assim como na questão anterior, calcularemos as condições de otimalidade de primeira e segunda ordem. Nesse sentido, o gradiente da função é $(2x_1 - x_2 - 2, 2x_2 - 2 - x_1)$. Portanto, igualando cada componente a zero encontramos seus pontos críticos:

$$\begin{cases} 2x_1 - x_2 - 2 = 0 \\ 2x_2 - 2 - x_1 = 0. \end{cases}$$

Obtemos o ponto crítico $(2, 2)$. Observando a matriz Hessiana e calculando seus menores principais, descobrimos que todos os seus menores principais são positivos.

$$\begin{aligned} |H_1| &= \left| \left[\frac{\partial f^2}{\partial x_1^2} \right] \right| = |[2]| = 2 \\ |H_2| &= \left| \begin{bmatrix} \frac{\partial f^2}{\partial x_1^2} & \frac{\partial f^2}{\partial x_1 \partial x_2} \\ \frac{\partial f^2}{\partial x_2 \partial x_1} & \frac{\partial f^2}{\partial x_2^2} \end{bmatrix} \right| = \left| \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \right| = 3 \end{aligned}$$

Logo, pelo teste de Sylvester, $f(2, 2) = -2$ é mínimo local. Além disso, por ser o único ponto crítico da função, também é mínimo global. ■

2. Questão 2

Enunciado: Faça uma síntese sobre um dos tópicos de otimização não linear irrestrita, exemplifique:

- Método de Newton (Escolhemos esse).
- Métodos de Máxima Descida

2.1. Método de Newton Clássico

Em análise numérica, o método de Newton-Raphson é um dos métodos mais eficientes para obtenção das raízes de uma função $f(x) = 0$. Começamos escolhendo a entrada inicial x_0 da função e calculamos a reta tangente ao ponto atual juntamente de sua interseção com o eixo das abscissas. Assim, repetimos esse processo até obter a interseção que corresponde à raiz da função.

O método de Newton é descrito pela seguinte sequência recursiva:

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}, n \in \mathbb{N}$$

onde x_n é a n -ésima iteração do algoritmo e $f'(x_n)$ é a derivada em x_n . Começamos a partir de uma estimativa x_0 e então iteramos até que o erro $\varepsilon_n = x_{n+1} - x_n$ seja menor que alguma tolerância aceitável que definimos.

2.2. Método de Newton em Otimização Não Linear Irrestrita

No contexto de otimização não linear irrestrita, o método de Newton é uma técnica iterativa que utiliza informações da função e de suas derivadas para encontrar os pontos críticos onde o gradiente da função é zero, podendo este ser um ponto de mínimo, máximo ou ponto de sela. Este método corresponde a uma extensão do método de Newton clássico para encontrar as raízes.

Para uma função $f : \mathbb{R}^n \rightarrow \mathbb{R}$, a ideia central do método é utilizar uma aproximação quadrática da função para iterativamente obter um ponto crítico. A estimativa da solução a cada iteração é calculada da seguinte forma:

$$x_{k+1} = x_k - H_f(x_k)^{-1} \nabla f(x_k)$$

Onde:

- x_k é o ponto atual na iteração k .
- $\nabla f(x_k)$ é o gradiente de f avaliado em x_k .
- $H_f(x_k)$ é a matriz Hessiana de f avaliada em x_k , ou seja, a matriz de segunda derivada de f .

2.2.1. Passo-a-Passo

1. **Gradiente:** Calcular o gradiente $\nabla f(x)$, que é um vetor de primeiras derivadas parciais da função f em relação a cada nível.
2. **Hessiana:** Calcular a matriz Hessiana $H_f(x)$, que é uma matriz de segundas derivadas parciais da função f definida na questão anterior.
3. **Resolução do Sistema Linear:** Resolver o sistema linear $H_f(x)d = -\nabla f(x_k)$ para encontrar a direção d . Onde $H_f(x_k)^{-1} \nabla f(x_k)$ é a direção do passo de Newton.
4. **Atualização da Solução:** Atualizar a solução x_k usando $x_{k+1} = x_k + d$.
5. **Repetição:** Repetir os passos anteriores até que a norma do gradiente $\|\nabla f(x_k)\|$ seja suficientemente pequena, indicando que x_k está próximo de um ponto crítico.

2.2.2. Prova

A demonstração do Método de Newton no contexto de otimização não linear irrestrita envolve a seguinte demonstração:

Convergência Local Quadrática: Se a aproximação inicial x_0 estiver suficientemente próxima ao ponto crítico x^* onde o gradiente $\nabla f(x^*) = 0$ e a Hessiana $H_f(x^*)$ é positiva definida, então a sequência gerada pelo Método de Newton convergirá para x^* com taxa quadrática.

Além disso, são necessárias algumas condições a mais para a convergência, tal como:

- **Matriz Hessiana Positiva Definida:** A matriz Hessiana $H_f(x^*)$ no ponto ótimo deve ser positiva definida. Isso nos garante que x^* seja um mínimo local e que o método converja.
- **Proximidade Inicial:** A aproximação x_0 deve ser próxima o bastante do ponto crítico x^* .
- **Classe C^2 :** A função deve ser duas vezes continuamente diferenciável. Isso permite a utilização de expansão de Taylor para aproximar a função.

Primeiramente, considere as seguintes suposições:

- x^* é um ponto crítico tal que $H_f(x^*)$ é positiva definida.
- A função f pertence à classe C^2 , ou seja, possui derivadas contínuas até a segunda ordem.

Como havíamos mencionado, a função f pode ser aproximada ao redor de x_k usando a expansão de Taylor de segunda ordem:

$$f(x) \approx f(x_k) + \nabla f(x_k)^T (x - x_k) + \frac{1}{2} (x - x_k)^T H_f(x_k) (x - x_k)$$

No ponto x_k , o gradiente é dado por $\nabla f(x_k)$. Assim, a atualização corresponde a;

$$x_{k+1} = x_k - H_f(x_k)^{-1} \nabla f(x_k).$$

Usando a expansão de Taylor para o gradiente $\nabla f(x)$ em torno de x_k :

$$\nabla f(x_{k+1}) \approx \nabla f(x_k) + H_f(x_k) (-H_f(x_k)^{-1} \nabla f(x_k)) = 0$$

Com base nisso, concluímos que o gradiente em x_{k+1} é zero, indicando que x_{k+1} é um ponto crítico. Para mostrar a convergência quadrática, vamos considerar a diferença $e_{k+1} = x_{k+1} - x^*$. Usando a definição de x_{k+1} e considerando que $\nabla f(x^*) = 0$:

$$e_{k+1} = x_{k+1} - x^* = x_k - H_f(x_k)^{-1} \nabla f(x_k) - x^*$$

Como x_k está próximo de x^* , podemos usar a expansão de Taylor para $\nabla f(x_k)$:

$$\nabla f(x_k) = H_f(x^*)(x_k - x^*) + \mathcal{O}(\|x_k - x^*\|^2)$$

Simplificando e usando $e_k = x_k - x^*$:

$$e_{k+1} = (I - H_f(x_k)^{-1} H_f(x^*)) e_k - H_f(x_k)^{-1} \mathcal{O}(\|e_k\|^2)$$

Se x_k está suficientemente próximo de x^* , podemos aproximar $H_f(x_k) \approx H_f(x^*)$, então:

$$e_{k+1} \approx -H_f(x^*)^{-1} \mathcal{O}(\|e_k\|^2)$$
$$\|e_{k+1}\| \approx C\|e_k\|^2$$

Onde C é uma constante, demonstrando que o erro decresce quadraticamente.

Bibliografia

- (1) Wikipedia. Hessiano, 2024.
- (2) Wikipedia. Método de Newton em otimização, 2024.
- (3) Wikipedia. Otimização, 2024.
- (4) Andretta, M. Gradientes, 2011.
- (5) Wikipedia. Método de Newton–Raphson, 2024.